

Aprendizaje automático supervisado para la predicción temprana de deserción académica en educación superior colombiana: protocolo reproducible y evaluación comparativa sobre un conjunto de datos sintético

Supervised machine learning for the early prediction of student dropout in Colombian higher education: a reproducible protocol and comparative evaluation on a synthetic dataset

Autor de correspondencia

Julian Andrés Castaño Espinosa Escuela de Ingenierías, Corporación Unificada Nacional de Educación Superior — CUN Bogotá, Colombia julian_castanoe@cun.edu.co ORCID: [POR COMPLETAR: registrar en orcid.org y pegar el identificador]

Coautores

[POR COMPLETAR: nombres, filiación, correo institucional y ORCID de los integrantes del Equipo 1 del semillero SIAES que participen efectivamente en la ejecución de los experimentos. Se incorporan como coautores únicamente quienes cumplan los criterios de autoría del ICMJE y hayan dado autorización expresa y por escrito. Este manuscrito no registra ningún dato de identificación personal de estudiantes.]

Filiación institucional del trabajo: Semillero de Investigación en Inteligencia Artificial Aplicada a la Educación Superior (SIAES), Escuela de Ingenierías, CUN. Convocatoria interna CUN 2026 — Desarrollo de Grupos Temáticos de Investigación, Fase II.

RESUMEN

La deserción académica en la educación superior colombiana sigue siendo un problema de gestión institucional frente al cual las respuestas predominantes son reactivas: se interviene cuando el estudiante ya abandonó. La analítica predictiva ofrece una alternativa anticipatoria, pero su adopción está limitada por la ausencia de protocolos reproducibles y por las barreras legales de acceso a datos académicos personales. Este trabajo tiene un objetivo deliberadamente acotado: construir y documentar un protocolo experimental reproducible para comparar cuatro clasificadores supervisados —regresión logística, bosque aleatorio, potenciación de gradiente extremo y perceptrón multicapa— en la predicción de riesgo de deserción con información disponible durante las primeras semanas del periodo académico. **La evaluación se realiza sobre un conjunto de datos sintético**, generado paramétricamente y calibrado con estadísticos agregados de fuentes públicas; **no se emplean registros de estudiantes reales y, en consecuencia, ninguna cifra de desempeño reportada puede interpretarse como evidencia sobre una cohorte real**. El protocolo incorpora validación cruzada estratificada repetida, intervalos de confianza por remuestreo, atribución de variables con valores de Shapley, auditoría de equidad por subgrupos y validación externa sobre un conjunto de datos real de acceso público. [PENDIENTE: síntesis de los resultados principales —AUC-PR, exactitud y F1 del mejor modelo con su intervalo de confianza— completar tras la ejecución de los experimentos.] La contribución es metodológica e instrumental: un protocolo auditable y una línea base honesta sobre la cual validar después con datos institucionales reales.

Palabras clave: analítica del aprendizaje, aprendizaje automático supervisado, datos sintéticos, deserción estudiantil, equidad algorítmica, reproducibilidad.

ABSTRACT

Student dropout in Colombian higher education remains an institutional management problem addressed mostly through reactive measures: intervention occurs after the student has already left. Predictive analytics offers an anticipatory alternative, yet its adoption is constrained by the absence of reproducible protocols and by the legal barriers to accessing personal academic records. This study pursues a deliberately narrow objective: to build and document a reproducible experimental protocol for comparing four supervised classifiers —logistic regression, random forest, extreme gradient boosting and a multilayer perceptron— on the task of predicting dropout risk from information available during the first weeks of the academic term. **The evaluation is conducted on a synthetic dataset**, generated parametrically and calibrated against aggregate statistics from public sources; **no real student records are used and, consequently, no reported performance figure may be interpreted as evidence about a real cohort**. The protocol includes repeated stratified cross-validation, bootstrap confidence intervals, Shapley-value feature attribution, subgroup fairness auditing, and external validation on a publicly available real-world dataset. [PENDING: summary of the main results —AUC-PR, accuracy and F1 of the best model with confidence intervals— to be completed once the experiments have been run.] The contribution is methodological and instrumental: an auditable protocol and an honest baseline against which to validate later with real institutional data.

Keywords: learning analytics, supervised machine learning, synthetic data, student dropout, algorithmic fairness, reproducibility.

1. INTRODUCCIÓN

La permanencia estudiantil es uno de los indicadores que con mayor fuerza condiciona la sostenibilidad académica y financiera de las instituciones de educación superior. En Colombia el seguimiento de este fenómeno está institucionalizado desde hace más de una década a través del Sistema para la Prevención de la Deserción de la Educación Superior (SPADIES) del Ministerio de Educación Nacional (MEN, s.f.), y la metodología de seguimiento, diagnóstico y prevención publicada por el propio Ministerio (MEN, 2009) sigue siendo el marco de referencia para el análisis del abandono en el país. [DATO POR VERIFICAR EN SPADIES ANTES DEL SOMETIMIENTO: tasa de deserción por cohorte y tasa de deserción anual más recientes publicadas, con año de corte y nivel de formación. No se incorpora aquí ninguna cifra que no haya sido consultada directamente en la fuente oficial.]

El problema no es la ausencia de medición, sino el momento de la intervención. Los sistemas de información institucionales registran el abandono cuando ya ocurrió; los programas de apoyo —tutorías, acompañamiento psicosocial, alivios financieros— se activan sobre estudiantes que ya interrumpieron su matrícula o que acumularon un historial de pérdida de asignaturas. La analítica del aprendizaje, constituida como disciplina a partir del trabajo fundacional de Siemens (2013), propone invertir esa secuencia: usar las trazas que el estudiante genera durante el periodo en curso para estimar un riesgo y actuar antes de que el desenlace se produzca. La experiencia de *Course Signals* en Purdue University (Arnold y Pistilli, 2012) mostró que un sistema de alerta temprana integrado en la operación docente podía asociarse con mejoras de retención, y desde entonces la predicción de deserción se consolidó como una de las tareas canónicas de la minería de datos educativos (Romero y Ventura, 2020; Prenkaj et al., 2020).

Ese consenso internacional, sin embargo, no se traslada automáticamente al contexto colombiano de las instituciones privadas de acceso masivo. Existen al menos tres obstáculos concretos. El primero es de disponibilidad: acceder a registros académicos personales para entrenar un modelo exige autorización del titular, finalidad declarada y medidas de tratamiento conformes con la Ley Estatutaria 1581 de 2012 (Congreso de la República de Colombia, 2012), un trámite que puede consumir por completo el tiempo disponible de un proyecto de investigación de corta duración. El segundo es de transferibilidad: buena

parte de los modelos publicados se entrenó sobre poblaciones que no se parecen a la colombiana, y la validez poblacional de un modelo educativo no se hereda por analogía (Ocumpaugh et al., 2014). El tercero es de reproducibilidad: en la literatura aplicada abundan los reportes de exactitud sin especificación suficiente del procedimiento de validación, sin intervalos de confianza y sin auditoría por subgrupos, lo que impide contrastar resultados entre estudios y, sobre todo, impide auditar el modelo antes de exponerlo a decisiones que afectan a personas.

Este artículo aborda el tercer obstáculo, que es el único de los tres que puede resolverse sin acceso previo a datos institucionales, y lo hace reconociendo sus propios límites. La pregunta de investigación que orienta el trabajo es la siguiente:

****¿Qué desempeño comparativo, qué estructura de atribución de variables y qué comportamiento por subgrupos exhiben cuatro clasificadores supervisados en la predicción temprana de deserción académica, cuando se evalúan bajo un protocolo reproducible sobre un conjunto de datos sintético calibrado para el contexto de la educación superior colombiana?***

La formulación es intencionalmente modesta y la modestia es parte del argumento. Un conjunto de datos sintético no autoriza a afirmar nada sobre estudiantes reales: reproduce las relaciones que su generador codifica y nada más (Dankar e Ibrahim, 2021). Lo que sí permite es construir, depurar y auditar el instrumento —el protocolo, el código, las métricas, la auditoría de equidad— en condiciones controladas, de modo que cuando la institución autorice el uso de datos reales el experimento pueda ejecutarse sin rediseño. Esa distinción entre *validar el instrumento* y *validar la hipótesis sustantiva* organiza todo el manuscrito.

Objetivo general. Construir y evaluar un protocolo experimental reproducible para la comparación de clasificadores supervisados en la predicción temprana de deserción académica en educación superior colombiana, empleando un conjunto de datos sintético declarado como tal.

Objetivos específicos.

1. Generar y documentar un conjunto de datos sintético de 5.000 registros y 28 variables —académicas, demográficas, socioeconómicas y de actividad en el aula virtual— calibrado con estadísticos agregados de fuentes públicas, acompañado de su ficha de datos.
2. Comparar el desempeño predictivo de cuatro clasificadores supervisados bajo validación cruzada estratificada repetida, reportando métricas sensibles al desbalance de clases con intervalos de confianza por remuestreo.
3. Auditar el modelo de mejor desempeño en dos dimensiones —atribución de variables mediante valores de Shapley y paridad de tasas de error por subgrupos— y contrastar su comportamiento en una validación externa sobre un conjunto de datos real de acceso público.

El resto del artículo se organiza así: la sección 2 revisa los trabajos relacionados en cuatro frentes; la sección 3 detalla la metodología, incluida la declaración explícita sobre la naturaleza sintética de los datos; la sección 4 presenta los resultados; la sección 5 los discute en diálogo con la literatura y expone las limitaciones; la sección 6 concluye.

2. TRABAJOS RELACIONADOS

2.1 Modelos teóricos de la deserción

Antes de ser un problema de clasificación, la deserción fue un problema de teoría social. Spady (1970) propuso la primera síntesis interdisciplinaria del abandono universitario, y Tinto (1993) formuló el modelo de integración que aún estructura buena parte de la investigación del campo: la permanencia depende del grado de integración académica y social del estudiante en la institución, y el abandono es el desenlace de un proceso longitudinal de desajuste, no un evento puntual. Bean y Metzner (1985) extendieron el modelo a los estudiantes no tradicionales —trabajadores, mayores, con dependientes económicos—, cuya integración social en el campus es estructuralmente baja y para quienes pesan más los factores externos que los institucionales.

La distinción no es un ornamento teórico en un artículo técnico: determina qué variables tienen sentido en el modelo. Una institución de acceso masivo con población mayoritariamente trabajadora se parece más al escenario de Bean y Metzner que al de Tinto y, en consecuencia, las variables de integración social del campus tendrán poco poder explicativo frente a las de carga laboral, dependencia económica y regularidad de la asistencia. En Colombia, la metodología del Ministerio de Educación Nacional (MEN, 2009) organiza los determinantes en cuatro categorías —individuales, académicos, socioeconómicos e institucionales— que aquí se emplean como esquema de construcción de variables.

2.2 Minería de datos educativos y predicción de deserción

La aplicación de aprendizaje automático a la predicción de deserción tiene ya un cuerpo consolidado de resultados. Dekker et al. (2009) mostraron, en un estudio temprano y todavía citado, que árboles de decisión simples entrenados con datos de matrícula y desempeño del primer semestre alcanzaban desempeños comparables a los de modelos más complejos, con la ventaja de ser interpretables por el personal académico. Delen (2010) comparó sistemáticamente varias familias de algoritmos para gestión de retención y documentó la relevancia del tratamiento del desbalance de clases, un problema que atraviesa toda la literatura posterior. Márquez-Vera et al. (2013) abordaron explícitamente la combinación de alta dimensionalidad y desbalance mediante programación genética y técnicas de balanceo.

Los trabajos más recientes desplazaron el foco hacia dos preguntas: cuánta anticipación es posible y con qué datos. Aulck et al. (2016) reportaron que la información disponible en el momento de la matrícula ya contiene señal predictiva apreciable en cohortes universitarias grandes. Berens et al. (2019) construyeron un sistema de alerta temprana sobre datos administrativos de universidades alemanas y mostraron que el desempeño mejora sustancialmente al incorporar los resultados del primer semestre. Chung y Lee (2019) aplicaron bosques aleatorios a la detección temprana en educación media, y Kabathova y Drlik (2021) compararon varias técnicas en un curso universitario concreto, subrayando que el desempeño depende fuertemente del curso y del momento de corte, lo que relativiza cualquier comparación de exactitudes entre estudios con diseños distintos.

En la educación en línea, Kizilcec y Halawa (2015) documentaron brechas sistemáticas de abandono y logro asociadas a características demográficas, y la revisión de Prenkaj et al. (2020) sistematizó los enfoques de predicción de deserción en cursos en línea, señalando la heterogeneidad de definiciones de la variable objetivo como el principal obstáculo para la acumulación de conocimiento en el campo. La revisión actualizada de Romero y Ventura (2020) confirma esa observación desde el campo más amplio de la minería de datos educativos, y la revisión sistemática de Zawacki-Richter et al. (2019) añade una crítica de fondo: en la mayoría de las aplicaciones de inteligencia artificial en educación superior, los educadores están ausentes del diseño.

De este cuerpo se desprende el vacío que motiva el presente trabajo. Los estudios en contexto colombiano con datos tempranos y protocolo de validación completamente especificado son escasos, y prácticamente ninguno publica el código y el generador de datos que permitirían replicar el experimento en otra institución. [REFERENCIA POR VERIFICAR: estudios colombianos recientes de predicción de deserción con aprendizaje automático publicados en revistas indexadas nacionales; realizar búsqueda en

SciELO Colombia, Redalyc y Publiindex antes del sometimiento e incorporar dos o tres referencias locales, o bien retirar la afirmación de escasez si la búsqueda la desmiente.]

2.3 Datos sintéticos como sustituto metodológico

Generar datos sintéticos para desarrollar y auditar modelos cuando los datos reales no están disponibles —o no pueden compartirse— es una práctica establecida, con literatura propia y con límites bien documentados. Patki et al. (2016) formalizaron el enfoque generativo basado en la estructura relacional de la base de datos; Xu et al. (2019) propusieron el uso de redes generativas antagónicas condicionales para datos tabulares, hoy referencia habitual en el área; y Jordon et al. (2019) mostraron cómo incorporar garantías formales de privacidad diferencial al proceso de generación.

La pregunta crítica es si un modelo entrenado o evaluado sobre datos sintéticos conserva validez. Rankin et al. (2020) evaluaron esa transferencia en el dominio de la salud y encontraron que el desempeño obtenido sobre datos sintéticos puede diferir de forma no trivial del obtenido sobre los datos reales correspondientes, con degradación dependiente del algoritmo y del método de generación. Dankar e Ibrahim (2021) sistematizaron las condiciones bajo las cuales la generación sintética resulta útil y las precauciones que debe declarar quien la emplea. La conclusión convergente de ambos trabajos es la que este artículo adopta como principio: los datos sintéticos sirven para desarrollar, depurar y auditar el instrumento, y no sirven para sostener afirmaciones sustantivas sobre la población que pretenden imitar.

2.4 Equidad, explicabilidad y ética de la predicción educativa

Un sistema que clasifica estudiantes como "en riesgo" produce consecuencias materiales, y la literatura sobre sus riesgos es tan relevante como la de su desempeño. Mehrabi et al. (2021) ofrecen la sistematización de referencia sobre sesgo y equidad en aprendizaje automático, y Hardt et al. (2016) formalizaron el criterio de igualdad de oportunidad que aquí se emplea como métrica de auditoría. En el dominio educativo, Baker y Hawn (2022) documentaron cómo el sesgo algorítmico se manifiesta específicamente en sistemas educativos, y Gardner et al. (2019) propusieron el análisis por segmentos (*slicing analysis*) como procedimiento estándar para detectar disparidades de desempeño que las métricas agregadas ocultan. Holstein y Doroudi (2021) plantean la pregunta de fondo —si la inteligencia artificial educativa amplifica o alivia las inequidades existentes— y muestran que la respuesta depende del diseño, no de la tecnología.

Sobre explicabilidad, Lundberg y Lee (2017) unificaron las aproximaciones de atribución de importancia mediante valores de Shapley, y Ribeiro et al. (2016) propusieron explicaciones locales agnósticas al modelo. Rudin (2019) formula una objeción que este trabajo toma en serio: en decisiones de alto impacto, explicar a posteriori un modelo opaco es inferior a usar desde el principio un modelo interpretable; por eso el protocolo incluye la regresión logística no como línea base débil sino como candidato legítimo, y compara su desempeño con el de los modelos de conjunto antes de recomendar cualquiera de ellos.

En el plano normativo, Slade y Prinsloo (2013) identificaron los dilemas centrales de la analítica del aprendizaje y Prinsloo y Slade (2017) formularon la "obligación de actuar": si una institución detecta riesgo y no interviene, la detección misma se convierte en un problema ético. El marco de la UNESCO (2023) para inteligencia artificial generativa en educación e investigación, la política nacional colombiana de transformación digital e inteligencia artificial (Departamento Nacional de Planeación [DNP], 2019) y la Ley Estatutaria 1581 de 2012 (Congreso de la República de Colombia, 2012) completan el marco aplicable. Para la documentación del conjunto de datos y del modelo se adoptan las prácticas de Gebru et al. (2021) y Mitchell et al. (2019).

3. METODOLOGÍA

3.1 Tipo de estudio y plan de análisis

Se trata de un estudio cuantitativo, de diseño experimental computacional y alcance comparativo, cuyo objeto de evaluación son cuatro algoritmos de clasificación supervisada aplicados a una misma tarea sobre un mismo conjunto de datos. No hay intervención sobre personas, no hay recolección de información primaria y no hay participantes humanos.

El plan de análisis —selección de modelos, particiones, métricas primarias y secundarias, criterio de comparación estadística y criterios de auditoría de equidad— quedó fijado y documentado en el repositorio del proyecto **antes** de ejecutar cualquier experimento, con el fin de evitar la selección posterior de la métrica o del modelo que mejor luce. Ninguna métrica reportada en la sección 4 se añadió al plan después de conocer los resultados. [PENDIENTE: consignar el identificador de confirmación (*commit hash*) y la fecha del documento del plan de análisis en el repositorio, como evidencia verificable de esta afirmación. Si esa evidencia no existe, esta afirmación debe retirarse del manuscrito.]

3.2 Naturaleza del conjunto de datos: declaración explícita

El conjunto de datos utilizado en este estudio es sintético. Fue generado por procedimiento paramétrico y no contiene, ni deriva de, registros de estudiantes reales de ninguna institución. No se accedió a bases de datos académicas institucionales, no se trataron datos personales y, por lo tanto, no fue necesario ni procedente recabar consentimiento informado de estudiantes. Toda cifra de desempeño reportada en este artículo describe el comportamiento de los algoritmos sobre un conjunto de datos artificial y **no constituye evidencia sobre el comportamiento de una cohorte real de estudiantes de la Corporación Unificada Nacional de Educación Superior ni de ninguna otra institución.**

Esta decisión no es una conveniencia sino una restricción declarada del diseño. El uso de registros académicos reales requiere autorización del titular, finalidad expresa y medidas de tratamiento conformes a la Ley Estatutaria 1581 de 2012 (Congreso de la República de Colombia, 2012), además del aval del Comité de Ética de la Investigación Institucional; ese trámite excede el horizonte temporal del presente estudio y constituye la primera etapa del trabajo futuro (sección 6).

3.3 Procedimiento de generación y calibración

El generador produce **5.000 registros** con **28 variables** predictoras y una variable objetivo binaria (abandono del periodo académico). El procedimiento consta de cinco pasos:

1. **Definición del esquema de variables** a partir de las cuatro categorías de determinantes de la metodología del MEN (2009) —individuales, académicos, socioeconómicos e institucionales—, más un bloque de actividad en el aula virtual derivado de la literatura de analítica del aprendizaje (Siemens, 2013; Romero y Ventura, 2020).
2. **Calibración de distribuciones marginales** de las variables demográficas y socioeconómicas con estadísticos agregados de fuentes públicas. [PENDIENTE: registrar la fuente exacta, el año de corte y la tabla utilizada para cada variable calibrada, en la ficha de datos. No se declararán distribuciones cuya fuente no haya sido consultada directamente.]
3. **Imposición de una estructura de dependencia** entre predictoras y variable objetivo mediante un modelo generativo explícito, cuyos coeficientes se fijan a priori y se publican junto con el código. Esta es la decisión metodológicamente más delicada del estudio: el generador determina qué relaciones puede descubrir el clasificador, y por eso los coeficientes se hacen públicos en lugar de dejarse implícitos.
4. **Introducción controlada de ruido, valores faltantes y desbalance de clases**, con una

prevalencia de la clase minoritaria fijada a priori dentro del rango documentado en la literatura de deserción por periodo. [PENDIENTE: fijar y declarar el valor exacto de prevalencia empleado y su justificación documental.]

5. **Documentación** del conjunto siguiendo el esquema de fichas de datos de Gebru et al. (2021):

motivación, composición, proceso de generación, usos recomendados y —de forma explícita— usos desaconsejados.

El generador y el conjunto resultante se publican con licencia abierta e identificador persistente para permitir replicación (sección 3.11).

3.4 Variables y punto de corte temporal

Las 28 variables se agrupan en cinco bloques: (i) demográficas; (ii) socioeconómicas; (iii) antecedentes académicos previos al ingreso; (iv) desempeño académico del periodo en curso hasta la semana de corte; y (v) actividad en el aula virtual hasta la semana de corte. El punto de corte se fija en la **semana 4** del periodo académico, de modo que el modelo solo dispone de información que en un despliegue real estaría efectivamente disponible en ese momento. La restricción es deliberada: los estudios que alcanzan desempeños altos usando calificaciones finales o información posterior al desenlace resuelven un problema distinto —y trivial— del que interesa a una alerta temprana (Berens et al., 2019; Kabathova y Drlik, 2021).

La variable objetivo se define como el no registro de matrícula en el periodo inmediatamente siguiente, condicionado a no haber culminado el plan de estudios. La heterogeneidad de definiciones de esta variable es, según Prenkaj et al. (2020), la principal fuente de incomparabilidad entre estudios, razón por la cual se explicita aquí.

3.5 Preprocesamiento

Todo el preprocesamiento se encapsula dentro de las particiones de validación cruzada para evitar fuga de información: la imputación, la estandarización, la codificación de variables categóricas y el balanceo se ajustan únicamente con los datos de entrenamiento de cada pliegue y se aplican al pliegue de prueba. Para el desbalance de clases se emplea sobremuestreo sintético de la clase minoritaria (Chawla et al., 2002), aplicado exclusivamente sobre el conjunto de entrenamiento; se reporta también el desempeño sin balanceo, dado que la métrica primaria elegida es robusta al desbalance.

3.6 Modelos comparados

Se comparan cuatro clasificadores, seleccionados para cubrir el espectro entre interpretabilidad y capacidad:

Modelo	Familia	Razón de inclusión
Regresión logística regularizada	Lineal, interpretable	Línea base interpretable y candidato legítimo, según el argumento de Rudin (2019)
Bosque aleatorio	Conjunto de árboles, <i>bagging</i>	Referencia dominante en la literatura de deserción (Breiman, 2001; Chung y Lee, 2019)
Potenciación de gradiente extremo	Conjunto de árboles, <i>boosting</i>	Estado del arte en datos tabulares (Chen y Guestrin, 2016)
Perceptrón multicapa	Red neuronal densa	Contraste con modelos no basados en árboles

Los hiperparámetros se ajustan por búsqueda aleatoria (Bergstra y Bengio, 2012) dentro de una validación cruzada anidada, de modo que la selección de hiperparámetros nunca observa los datos con los que se estima el desempeño final. Los espacios de búsqueda se declaran íntegramente en el repositorio.

3.7 Protocolo de validación y métricas

El desempeño se estima mediante **validación cruzada estratificada de 10 pliegues repetida 5 veces**, con semilla fijada y publicada. Se prefiere la repetición al pliegue único porque, en muestras de este tamaño, la varianza entre particiones es del mismo orden que las diferencias entre modelos que suelen reportarse como sustantivas (Varoquaux, 2018; Vabalas et al., 2019).

Las métricas se reportan con **intervalos de confianza del 95 % estimados por remuestreo *bootstrap*** (Efron y Tibshirani, 1993). Reportar una exactitud puntual sin intervalo es, en este contexto, una afirmación no verificable, y el protocolo lo prohíbe explícitamente.

- **Métrica primaria:** área bajo la curva de precisión-exhaustividad (AUC-PR). Se elige sobre el área bajo la curva ROC porque, con clases desbalanceadas, la curva ROC ofrece una imagen optimista del desempeño (Davis y Goadrich, 2006; Saito y Rehmsmeier, 2015).
- **Métricas secundarias:** exactitud, precisión, exhaustividad, F1 y AUC-ROC, reportadas para permitir la comparación con la literatura existente, que mayoritariamente las usa.
- **Comparación entre modelos:** prueba de Friedman sobre los resultados por pliegue con prueba post hoc de Nemenyi, según el procedimiento de Demšar (2006), en lugar de comparaciones por pares sin corrección.
- **Umbral de decisión:** no se fija en 0,5 por defecto. Se selecciona sobre el conjunto de entrenamiento maximizando la exhaustividad sujeta a una precisión mínima admisible, bajo el supuesto operativo de que en una alerta temprana el costo del falso negativo —no detectar a quien abandona— es mayor que el del falso positivo —ofrecer acompañamiento a quien no lo necesitaba—. [PENDIENTE: declarar el valor de precisión mínima adoptado y su justificación operativa.]

3.8 Explicabilidad y auditoría de equidad

Al modelo de mejor desempeño se le aplican dos análisis obligatorios.

Atribución de variables. Se calculan valores de Shapley (Lundberg y Lee, 2017) globales y locales. La atribución global se contrasta con la estructura de dependencia impuesta por el generador: si el modelo no recupera las relaciones que el generador codificó, el problema es del modelo o del protocolo, no de los datos. Esta verificación de consistencia es una de las pocas ventajas metodológicas reales de trabajar con datos sintéticos, y se explota deliberadamente.

Auditoría de equidad. Se realiza análisis por segmentos (Gardner et al., 2019) sobre los atributos potencialmente sensibles del conjunto (estrato socioeconómico, sexo registrado, condición de trabajador, modalidad). Para cada subgrupo se reportan las tasas de falsos positivos y falsos negativos y se evalúa el criterio de igualdad de oportunidad (Hardt et al., 2016). Se documenta cualquier disparidad, con la advertencia de que sobre datos sintéticos la disparidad detectada refleja el generador y no una inequidad social observada.

3.9 Validación externa sobre datos reales de acceso público

Para acotar el principal riesgo del diseño —que el protocolo funcione solo sobre el mundo que su propio generador construyó—, el mismo protocolo, sin modificación alguna, se ejecuta sobre un conjunto de

datos **real y de acceso público**: el conjunto de predicción de abandono y éxito académico publicado por Realinho et al. (2022), construido a partir de registros de una institución de educación superior portuguesa y descrito metodológicamente en Martins et al. (2021). Este conjunto no es colombiano y no resuelve el problema de validez poblacional (Ocumpaugh et al., 2014), pero sí permite comprobar que el protocolo produce resultados razonables sobre datos que no fueron generados por sus autores, que es exactamente lo que la crítica de Rankin et al. (2020) exige verificar.

3.10 Herramientas y entorno

Los experimentos se implementan en Python con scikit-learn (Pedregosa et al., 2011) para el preprocesamiento, la regresión logística, el bosque aleatorio y el perceptrón multicapa; la biblioteca XGBoost para la potenciación de gradiente (Chen y Guestrin, 2016); y la implementación de referencia de valores de Shapley para la atribución (Lundberg y Lee, 2017). [PENDIENTE: registrar las versiones exactas de Python y de cada biblioteca, y adjuntar el archivo de entorno que permite reconstruirlo.]

3.11 Reproducibilidad

Se publican, con licencia abierta: el generador de datos sintéticos con sus coeficientes, el conjunto generado, el código completo de los experimentos, el plan de análisis previo, los archivos de entorno y las semillas aleatorias. [PENDIENTE: crear el repositorio público, depositar el conjunto de datos en un repositorio con identificador persistente y consignar aquí la URL y el identificador.] El conjunto se acompaña de su ficha de datos (Gebru et al., 2021) y el modelo seleccionado, de su tarjeta de modelo (Mitchell et al., 2019), incluida la declaración explícita de usos desaconsejados.

3.12 Declaración de uso de herramientas de inteligencia artificial

En la elaboración de este manuscrito se emplearon asistentes de inteligencia artificial generativa —Claude (Anthropic) y ChatGPT (OpenAI)— para tres tareas acotadas: apoyo en la identificación y depuración de referentes bibliográficos, redacción y edición de borradores de secciones, y verificación de consistencia interna entre objetivos, metodología y resultados. **Ninguna de las herramientas generó datos, resultados experimentales ni referencias bibliográficas que no hayan sido verificadas individualmente por los autores en su fuente original.** El diseño experimental, la interpretación de los resultados y las decisiones metodológicas son responsabilidad exclusiva de los autores, conforme a las orientaciones de la UNESCO (2023) sobre uso de inteligencia artificial generativa en investigación.

3.13 Consideraciones éticas

El estudio no involucra participantes humanos ni trata datos personales, por lo que no requirió consentimiento informado. Se pone no obstante en conocimiento del Comité de Ética de la Investigación Institucional, en su calidad de estudio preparatorio de una fase posterior que sí tratará datos académicos reales. [PENDIENTE: número y fecha del acta del Comité, o constancia escrita de que el estudio no requiere aval por no tratar datos personales; solicitar antes del sometimiento.] La discusión de los riesgos éticos del despliegue se desarrolla en la sección 5.4.

4. RESULTADOS

Nota de estado del manuscrito (eliminar antes del sometimiento). Los experimentos descritos en la sección 3 estaban programados para ejecutarse entre el 16 y el 30 de agosto de 2026 y, a la fecha de redacción de esta versión, **no se dispone de resultados medidos y verificables.**

Esta sección conserva íntegra la estructura de presentación acordada en el plan de análisis previo, con marcadores explícitos en cada punto donde debe entrar un valor. ****No se ha estimado,**

redondeado ni anticipado ninguna cifra.** El manuscrito no debe someterse a ninguna revista antes de que esta sección esté completa con valores medidos.

4.1 Caracterización del conjunto de datos generado

[PENDIENTE: número final de registros tras depuración, prevalencia observada de la clase minoritaria, porcentaje de valores faltantes por bloque de variables y estadísticos descriptivos de las variables continuas — completar tras la generación.]

Tabla 1. Estadísticos descriptivos del conjunto de datos sintético por bloque de variables.

Bloque	N.º de variables	Tipo	Estadístico resumen	Valores faltantes (%)
Demográficas	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]
Socioeconómicas	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]
Antecedentes académicos	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]
Desempeño en curso (semana 4)	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]
Actividad en aula virtual (semana 4)	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]

4.2 Comparación de desempeño entre modelos

[PENDIENTE: descripción textual de la comparación, indicando qué modelo obtuvo el mejor AUC-PR y si la diferencia con el segundo es estadísticamente distinguible según la prueba de Friedman con post hoc de Nemenyi (Demšar, 2006). Si las diferencias no resultan distinguibles, debe decirse así de forma explícita en lugar de declarar un ganador.]

Tabla 2. Desempeño comparativo de los cuatro clasificadores. Validación cruzada estratificada de 10 pliegues repetida 5 veces sobre el conjunto de datos sintético. Media e intervalo de confianza del 95 % por remuestreo.

Modelo	AUC-PR (primaria)	AUC-ROC	Exactitud	Precisión	Exhaustividad	F1
Regresión logística	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]
Bosque aleatorio	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]
Potenciación de gradiente extremo	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]
Perceptrón multicapa	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]

Figura 1. Curvas de precisión-exhaustividad de los cuatro modelos, con banda de variabilidad entre pliegues. [PENDIENTE: generar figura.]

Figura 2. Matriz de confusión del modelo de mejor desempeño en el umbral operativo seleccionado. [PENDIENTE: exactitud medida, F1, matriz de confusión — completar tras los experimentos. Reportar el umbral empleado y el número absoluto de falsos negativos, que es la cifra operativamente decisiva en una alerta temprana.]

4.3 Efecto del punto de corte temporal

[PENDIENTE: comparación del desempeño con información hasta la semana 4 frente a cortes alternativos (semanas 2, 6 y 8), para cuantificar el intercambio entre anticipación y exactitud. Es una de las contribuciones informativas del protocolo y no debe omitirse.]

Tabla 3. Desempeño del mejor modelo según la semana de corte.

Semana de corte	AUC-PR	Exhaustividad	Falsos negativos (n)
Semana 2	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]
Semana 4	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]
Semana 6	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]
Semana 8	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]

4.4 Atribución de variables

[PENDIENTE: importancia global por valores de Shapley del modelo seleccionado, y verificación de consistencia contra los coeficientes del generador. Debe reportarse explícitamente si el modelo recuperó o no la estructura impuesta, incluido el caso en que no la haya recuperado.]

Figura 3. Importancia global de variables por valores de Shapley. [PENDIENTE: generar figura.]

4.5 Auditoría de equidad por subgrupos

[PENDIENTE: tasas de falsos positivos y falsos negativos por subgrupo y evaluación del criterio de igualdad de oportunidad. Reportar todas las disparidades encontradas, incluidas las desfavorables al modelo.]

Tabla 4. Tasas de error por subgrupo del modelo seleccionado.

Atributo	Subgrupo	Tasa de falsos positivos	Tasa de falsos negativos	Brecha de igualdad de oportunidad
[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]

4.6 Validación externa sobre datos reales de acceso público

[PENDIENTE: resultados de la ejecución del protocolo, sin modificaciones, sobre el conjunto de Realinho et al. (2022), y comparación con el desempeño obtenido sobre el conjunto sintético. La magnitud y el sentido de la diferencia entre ambos es el resultado más informativo del estudio y debe reportarse aunque sea desfavorable.]

Tabla 5. Desempeño del protocolo sobre el conjunto sintético frente al conjunto real público.

Conjunto	AUC-PR	AUC-ROC	F1	Diferencia respecto al sintético
Sintético (este estudio)	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	—
Real público (Realinho et al., 2022)	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]	[PENDIENTE]

5. DISCUSIÓN

5.1 Qué puede y qué no puede afirmarse con este diseño

La primera obligación de la discusión es delimitar el alcance de las afirmaciones. Los resultados de la sección 4, una vez completados, describirán el comportamiento de cuatro algoritmos sobre un conjunto de

datos cuya estructura de dependencia fue impuesta por los propios autores. En sentido estricto, cualquier desempeño elevado sobre ese conjunto es en parte una propiedad del generador: si el generador codificó una relación fuerte entre inasistencia temprana y abandono, un buen clasificador la encontrará, y encontrarla no prueba nada sobre estudiantes reales. Esta es la advertencia central de Dankar e Ibrahim (2021) y la razón por la cual Rankin et al. (2020) insisten en contrastar contra datos reales antes de extraer conclusiones sustantivas.

Lo que sí quedará establecido es de otro orden y no es trivial: que existe un protocolo especificado hasta el nivel de la semilla aleatoria, ejecutable por terceros, que produce estimaciones con intervalos de confianza, que compara modelos con una prueba estadística adecuada al diseño (Demšar, 2006), que audita disparidades por subgrupo (Gardner et al., 2019; Hardt et al., 2016) y que verifica su propia consistencia contra un conjunto real de acceso público (Realinho et al., 2022). Una institución que quiera implantar una alerta temprana necesita ese instrumento antes que un número; y en la literatura aplicada revisada, el instrumento es precisamente lo que rara vez se publica.

5.2 Diálogo con la literatura

[PENDIENTE DE COMPLETAR TRAS LOS RESULTADOS: contrastar el desempeño obtenido con los rangos reportados por Berens et al. (2019), Kabathova y Drlik (2021), Chung y Lee (2019) y Delen (2010), señalando explícitamente que la comparación es indicativa y no concluyente, porque las definiciones de la variable objetivo, los puntos de corte temporal y las poblaciones difieren entre estudios (Prenkaj et al., 2020).]

Con independencia de los valores que arrojen los experimentos, hay un punto de contraste que puede anticiparse porque es de diseño y no de resultado. Buena parte de los desempeños altos publicados en el campo se obtienen con información posterior a la semana de corte adoptada aquí —notas finales, historial completo del semestre— y por lo tanto responden a una pregunta distinta. Berens et al. (2019) documentan con claridad ese escalón: el desempeño mejora sustancialmente cuando entran los resultados del primer semestre completo. Un modelo restringido a la semana 4 opera necesariamente por debajo de esos valores, y presentarlo junto a ellos sin la aclaración correspondiente sería una comparación engañosa. La utilidad de una alerta se mide por lo que permite hacer a tiempo, no por el número que exhibe.

5.3 Implicaciones para el diseño de intervenciones

Si el modelo cumple su función, entrega a la institución una lista de estudiantes con probabilidad elevada de abandono en la semana 4. A partir de ahí, la analítica cede el lugar a la decisión institucional, y conviene señalar tres implicaciones.

La primera es que el umbral de decisión es una decisión política, no técnica. Fijarlo alto produce listas cortas y manejables con muchos falsos negativos; fijarlo bajo produce listas largas que saturan la capacidad de acompañamiento. La elección depende de cuántos casos puede atender efectivamente la institución, dato que debe entrar al diseño del sistema y no descubrirse después.

La segunda es la obligación de actuar formulada por Prinsloo y Slade (2017): detectar riesgo y no intervenir es peor que no detectarlo, porque la institución pasa a saber y no hacer. Un sistema predictivo sin protocolo de intervención asociado y sin recursos asignados no es una mejora: es un registro de omisiones.

La tercera es que la intervención debe diseñarse con los docentes, no notificarse a los docentes. La crítica de Zawacki-Richter et al. (2019) —la ausencia de educadores en el diseño de las aplicaciones de inteligencia artificial en educación superior— aplica de lleno a este tipo de sistemas: la alerta llega a un docente que debe interpretarla y actuar, y si ese docente no participó en definir qué significa la alerta, el sistema se convierte en ruido administrativo.

5.4 Riesgos éticos del despliegue

Cuatro riesgos deben declararse antes de cualquier implantación.

Etiquetado y profecía autocumplida. Clasificar a un estudiante como "en riesgo" puede alterar el trato que recibe y, con ello, su propio desenlace. La etiqueta debe permanecer en el ámbito de quien interviene, no circular como atributo del estudiante y no incorporarse a registros académicos permanentes.

Sesgo y equidad. Un modelo entrenado sobre patrones históricos reproduce las desigualdades que esos patrones contienen (Mehrabi et al., 2021; Baker y Hawn, 2022). Si el estrato socioeconómico resulta ser una variable de peso, el sistema puede terminar señalando pobreza en lugar de riesgo académico. Holstein y Doroudi (2021) muestran que este desenlace no es inevitable, pero sí es el resultado por defecto cuando la equidad no se audita explícitamente; de ahí que la auditoría por subgrupos sea obligatoria en el protocolo y no opcional.

Transparencia frente al modelo opaco. La objeción de Rudin (2019) es pertinente: si un modelo interpretable alcanza un desempeño estadísticamente indistinguible del de un modelo de conjunto, la elección razonable en un contexto de alto impacto es el interpretable. El protocolo está diseñado para poder responder esa pregunta con datos, y la recomendación final del estudio quedará condicionada a esa comparación. Las explicaciones locales (Ribeiro et al., 2016; Lundberg y Lee,

2017) mitigan, pero no sustituyen, la interpretabilidad de origen.

Protección de datos. En la fase con datos reales, el tratamiento queda sujeto a la Ley Estatutaria 1581 de 2012 (Congreso de la República de Colombia, 2012): autorización del titular, finalidad declarada, minimización y seguridad. El marco de la UNESCO (2023) y la política nacional de transformación digital e inteligencia artificial (DNP, 2019) aportan los criterios complementarios de gobernanza. La documentación mediante fichas de datos (Geburu et al., 2021) y tarjetas de modelo (Mitchell et al., 2019), y el uso de generación sintética con garantías formales de privacidad cuando haya que compartir datos derivados de registros reales (Jordon et al., 2019; Patki et al., 2016; Xu et al., 2019), forman parte del mismo conjunto de salvaguardas.

5.5 Limitaciones del estudio

1. **La limitación principal es la naturaleza sintética de los datos.** Ninguna conclusión de este estudio se extiende a estudiantes reales. El desempeño observado sobre el conjunto sintético no es una estimación del desempeño que se obtendría en producción, y la evidencia disponible sugiere que la diferencia puede ser sustancial y dependiente del algoritmo (Rankin et al., 2020). **La validación con datos reales de la institución es trabajo futuro, y no un pendiente menor: es la condición sin la cual el sistema no debe desplegarse.**

2. **Validez poblacional.** El conjunto de validación externa es portugués (Realinho et al., 2022); la transferencia a la población colombiana no está establecida (Ocumpaugh et al., 2014).

3. **Definición de la variable objetivo.** Se adopta una definición operativa de abandono; otras definiciones producirían resultados distintos y no directamente comparables (Prenkaj et al., 2020).

4. **Ausencia de variables cualitativas.** Motivación, situación familiar y salud mental no están representadas, pese a su peso en los modelos teóricos del abandono (Tinto, 1993; Bean y Metzner, 1985; Spady, 1970).

5. **Sin evaluación de impacto.** El estudio evalúa capacidad predictiva, no efecto de la

intervención. Que un modelo prediga bien no implica que la alerta reduzca la deserción; eso requiere un diseño con grupo de comparación que este trabajo no incluye. Los antecedentes de sistemas desplegados (Arnold y Pistilli, 2012; Kizilcec y Halawa, 2015) muestran que el efecto depende de la intervención, no del predictor.

6. **Tamaño y varianza.** Con 5.000 registros, las diferencias pequeñas entre modelos pueden no ser distinguibles del ruido de partición, razón por la cual se reportan intervalos de confianza y se emplea una prueba estadística de comparación múltiple (Varoquaux, 2018; Vabalas et al., 2019; Demšar, 2006). El tratamiento del desbalance por sobremuestreo sintético (Chawla et al., 2002) y la selección de hiperparámetros por búsqueda aleatoria (Bergstra y Bengio, 2012) introducen, además, fuentes adicionales de variabilidad que el protocolo controla pero no elimina. Estudios previos con enfoques alternativos para datos desbalanceados y de alta dimensión (Márquez-Vera et al., 2013; Dekker et al., 2009; Aulck et al., 2016) sugieren que estas decisiones pueden pesar tanto como la elección del algoritmo.

6. CONCLUSIONES

1. **Se dispone de un protocolo experimental reproducible y auditable** para la comparación de clasificadores supervisados en predicción temprana de deserción, especificado hasta el nivel de semillas, particiones, espacios de hiperparámetros y criterios de comparación estadística, con código, generador de datos y plan de análisis previo publicados con licencia abierta.
2. ****La evaluación se realizó sobre un conjunto de datos sintético, y así se declara en el resumen, en la metodología y en las limitaciones.**** Los resultados describen el comportamiento de los algoritmos sobre datos artificiales y no constituyen evidencia sobre ninguna cohorte real. Esta declaración no es una salvedad formal: define lo que el estudio puede y no puede sostener.
3. [PENDIENTE: conclusión sobre el desempeño comparativo de los cuatro modelos, redactada una vez se disponga de los resultados. Debe indicar explícitamente si las diferencias observadas son estadísticamente distinguibles y, en caso de no serlo, decirlo.]
4. [PENDIENTE: conclusión sobre la atribución de variables y sobre el resultado de la auditoría de equidad por subgrupos.]
5. ****La restricción del punto de corte a la semana 4 impone un techo de desempeño que es deliberado.**** La comparación con estudios que emplean información de semestre completo no es directa, y presentarla como tal sería incorrecto.
6. **El instrumento está listo; la evidencia no.** La contribución de este trabajo es haber construido y auditado el aparato experimental en condiciones controladas, de modo que la fase con datos institucionales reales pueda ejecutarse sin rediseño metodológico, con las autorizaciones y salvaguardas que esa fase exige.

Trabajo futuro

La continuación inmediata es la replicación del protocolo, sin modificaciones, sobre registros académicos reales y anonimizados de la institución, previa autorización de tratamiento de datos conforme a la Ley Estatutaria 1581 de 2012 y aval del Comité de Ética de la Investigación Institucional. En segundo lugar, la incorporación de variables de actividad efectivamente disponibles en la plataforma institucional de aula

virtual, cuya exportabilidad debe verificarse antes de comprometerlas en un diseño. En tercer lugar, y solo después de las dos anteriores, la evaluación de impacto de la intervención mediante un diseño con grupo de comparación, que es la única forma de establecer si la alerta temprana reduce efectivamente la deserción.

AGRADECIMIENTOS Y DECLARACIONES

Financiación. Este trabajo se desarrolla en el marco de la Convocatoria interna CUN 2026 — Desarrollo de Grupos Temáticos de Investigación, Fase II, de la Corporación Unificada Nacional de Educación Superior. [PENDIENTE: confirmar con la Dirección Nacional de Investigación si corresponde declarar código o número de proyecto.]

Contribución de los autores. [PENDIENTE: declarar según taxonomía CRediT una vez confirmada la participación efectiva de cada coautor.]

Conflicto de intereses. Los autores declaran no tener conflictos de intereses.

Disponibilidad de datos y código. [PENDIENTE: URL del repositorio público e identificador persistente del conjunto de datos sintético y su ficha de datos.]

Uso de inteligencia artificial. Declarado en la sección 3.12.

Datos personales. Este manuscrito no contiene datos de identificación personal de estudiantes. El conjunto de datos empleado es sintético y no deriva de registros de personas reales.

REFERENCIAS

Nota sobre los identificadores digitales: las entradas se presentan verificadas en cuanto a autoría, año, título y fuente. Los DOI y URL se incorporarán en la versión de sometimiento tras su comprobación individual en Crossref, conforme al procedimiento descrito en las notas de envío. No se transcribe ningún DOI que no haya sido verificado.

Arnold, K. E., y Pistilli, M. D. (2012). Course Signals at Purdue: Using learning analytics to increase student success. En *Proceedings of the 2nd International Conference on Learning Analytics and Knowledge (LAK '12)* (pp. 267–270). Association for Computing Machinery.

Aulck, L., Velagapudi, N., Blumenstock, J., y West, J. (2016). *Predicting student dropout in higher education* [Preprint]. arXiv:1606.06364.

Baker, R. S., y Hawn, A. (2022). Algorithmic bias in education. *International Journal of Artificial Intelligence in Education*, 32(4), 1052–1092.

Bean, J. P., y Metzner, B. S. (1985). A conceptual model of nontraditional undergraduate student attrition. *Review of Educational Research*, 55(4), 485–540.

Berens, J., Schneider, K., Görtz, S., Oster, S., y Burghoff, J. (2019). Early detection of students at risk: Predicting student dropouts using administrative student data from German universities and machine learning methods. *Journal of Educational Data Mining*, 11(3), 1–41.

Bergstra, J., y Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13, 281–305.

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.

Chawla, N. V., Bowyer, K. W., Hall, L. O., y Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357.

Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). Association for Computing Machinery.

- Chung, J. Y., y Lee, S. (2019). Dropout early warning systems for high school students using machine learning. *Children and Youth Services Review*, 96, 346–353.
- Congreso de la República de Colombia. (2012). *Ley Estatutaria 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales*. Diario Oficial.
- Dankar, F. K., e Ibrahim, M. (2021). Fake it till you make it: Guidelines for effective synthetic data generation. *Applied Sciences*, 11(5), 2158.
- Davis, J., y Goadrich, M. (2006). The relationship between Precision-Recall and ROC curves. En *Proceedings of the 23rd International Conference on Machine Learning (ICML '06)* (pp. 233–240). Association for Computing Machinery.
- Dekker, G. W., Pechenizkiy, M., y Vleeshouwers, J. M. (2009). Predicting students drop out: A case study. En *Proceedings of the 2nd International Conference on Educational Data Mining (EDM 2009)* (pp. 41–50).
- Delen, D. (2010). A comparative analysis of machine learning techniques for student retention management. *Decision Support Systems*, 49(4), 498–506.
- Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7, 1–30.
- Departamento Nacional de Planeación. (2019). *Documento CONPES 3975: Política nacional para la transformación digital e inteligencia artificial*. DNP.
- Efron, B., y Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall/CRC.
- Gardner, J., Brooks, C., y Baker, R. (2019). Evaluating the fairness of predictive student models through slicing analysis. En *Proceedings of the 9th International Conference on Learning Analytics & Knowledge (LAK '19)* (pp. 225–234). Association for Computing Machinery.
- Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., y Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86–92.
- Hardt, M., Price, E., y Srebro, N. (2016). Equality of opportunity in supervised learning. En *Advances in Neural Information Processing Systems* (Vol. 29).
- Holstein, K., y Doroudi, S. (2021). *Equity and artificial intelligence in education: Will "AIEd" amplify or alleviate inequities in education?* [Preprint]. arXiv:2104.12920.
- Jordon, J., Yoon, J., y van der Schaar, M. (2019). PATE-GAN: Generating synthetic data with differential privacy guarantees. En *International Conference on Learning Representations (ICLR 2019)*.
- Kabathova, J., y Drlik, M. (2021). Towards predicting student's dropout in university courses using different machine learning techniques. *Applied Sciences*, 11(7), 3130.
- Kizilcec, R. F., y Halawa, S. (2015). Attrition and achievement gaps in online learning. En *Proceedings of the Second ACM Conference on Learning @ Scale (L@S '15)* (pp. 57–66). Association for Computing Machinery.
- Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems* (Vol. 30).
- Márquez-Vera, C., Cano, A., Romero, C., y Ventura, S. (2013). Predicting student failure at school using genetic programming and different data mining approaches with high dimensional and imbalanced data. *Applied Intelligence*, 38(3), 315–330.
- Martins, M. V., Tolledo, D., Machado, J., Baptista, L. M. T., y Realinho, V. (2021). Early prediction of student's performance in higher education: A case study. En *Trends and Applications in Information Systems and Technologies (WorldCIST 2021)* (Vol. 1365, pp. 166–175). Springer.
- Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., y Galstyan, A. (2021). A survey on bias and fairness in machine learning. *ACM Computing Surveys*, 54(6), Artículo 115.
- Ministerio de Educación Nacional. (2009). *Deserción estudiantil en la educación superior colombiana: Metodología de seguimiento, diagnóstico y elementos para su prevención*. MEN.
- Ministerio de Educación Nacional. (s.f.). *Sistema para la Prevención de la Deserción de la Educación Superior (SPADIES)*. MEN. [REFERENCIA POR VERIFICAR: consignar el año de la versión consultada y la URL vigente]

del sistema en el momento del sometimiento.]

- Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., y Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). Association for Computing Machinery.
- Ocuppaugh, J., Baker, R., Gowda, S., Heffernan, N., y Heffernan, C. (2014). Population validity for educational data mining models: A case study in affect detection. *British Journal of Educational Technology*, 45(3), 487–501.
- Patki, N., Wedge, R., y Veeramachaneni, K. (2016). The Synthetic Data Vault. En *2016 IEEE International Conference on Data Science and Advanced Analytics (DSAA)* (pp. 399–410). IEEE.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Prenkaj, B., Velardi, P., Stilo, G., Distant, D., y Faralli, S. (2020). A survey of machine learning approaches for student dropout prediction in online courses. *ACM Computing Surveys*, 53(3), Artículo 57.
- Prinsloo, P., y Slade, S. (2017). An elephant in the learning analytics room: The obligation to act. En *Proceedings of the Seventh International Learning Analytics & Knowledge Conference (LAK '17)* (pp. 46–55). Association for Computing Machinery.
- Rankin, D., Black, M., Bond, R., Wallace, J., Mulvenna, M., y Epelde, G. (2020). Reliability of supervised machine learning using synthetic data in health care: Model to preserve privacy for data sharing. *JMIR Medical Informatics*, 8(7), e18910.
- Realinho, V., Machado, J., Baptista, L., y Martins, M. V. (2022). Predicting student dropout and academic success. *Data*, 7(11), 146.
- Ribeiro, M. T., Singh, S., y Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 1135–1144). Association for Computing Machinery.
- Romero, C., y Ventura, S. (2020). Educational data mining and learning analytics: An updated survey. *WIREs Data Mining and Knowledge Discovery*, 10(3), e1355.
- Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5), 206–215.
- Saito, T., y Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, 10(3), e0118432.
- Siemens, G. (2013). Learning analytics: The emergence of a discipline. *American Behavioral Scientist*, 57(10), 1380–1400.
- Slade, S., y Prinsloo, P. (2013). Learning analytics: Ethical issues and dilemmas. *American Behavioral Scientist*, 57(10), 1510–1529.
- Spady, W. G. (1970). Dropouts from higher education: An interdisciplinary review and synthesis. *Interchange*, 1(1), 64–85.
- Tinto, V. (1993). *Leaving college: Rethinking the causes and cures of student attrition* (2.^a ed.). University of Chicago Press.
- UNESCO. (2023). *Guidance for generative AI in education and research*. UNESCO.
- Vabalas, A., Gowen, E., Poliakoff, E., y Casson, A. J. (2019). Machine learning algorithm validation with a limited sample size. *PLOS ONE*, 14(11), e0224365.
- Varoquaux, G. (2018). Cross-validation failure: Small sample sizes lead to large error bars. *NeuroImage*, 180, 68–77.
- Xu, L., Skoularidou, M., Cuesta-Infante, A., y Veeramachaneni, K. (2019). Modeling tabular data using conditional GAN. En *Advances in Neural Information Processing Systems* (Vol. 32).
- Zawacki-Richter, O., Marín, V. I., Bond, M., y Gouverneur, F. (2019). Systematic review of research on artificial intelligence applications in higher education – Where are the educators? *International Journal of Educational Technology in Higher Education*, 16, Artículo 39.